UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO III – CURSO CIÊNCIA DE DADOS

TURMA 201825166.000.03A – GRUPO 12

GUILHERME AUGUSTO LEAL OLIVEIRA

GUILHERME ROCHA DE SOUZA DUARTE

RICARDO ZULIAN DE SOUZA AMARAL

SISTEMA DE RECOMENDAÇÃO DE CURSOS EDUCACIONAIS COM BASE EM AVALIAÇÕES DE USUÁRIOS

São Paulo

2026

TURMA 201825166.000.03A – GRUPO 12

GUILHERME AUGUSTO LEAL OLIVEIRA

GUILHERME ROCHA DE SOUZA DUARTE

RICARDO ZULIAN DE SOUZA AMARAL

SISTEMA DE RECOMENDAÇÃO DE CURSOS EDUCACIONAIS COM BASE EM AVALIAÇÕES DE USUÁRIOS

Projeto aplicado apresentado à Universidade Presbiteriana Mackenzie como requisito parcial para conclusão da disciplina Projeto Aplicado III.

Orientadora: Professora Carolina Toledo Ferraz

São Paulo

2026

SUMÁRIO

1 INTRODUÇÃO 3

1.1 Contexto do Trabalho 3

1.2 Motivação 3

1.3 Justificativa 3

1.4 Objetivos 4

2 REFERENCIAL TEÓRICO 5

3 METODOLOGIA 9

3.1 Definição do Problema e Objetivos 9

3.2 Coleta de Dados 9

3.3 Pré-processamento e Limpeza dos Dados 10

3.4 Divisão dos Dados 10

3.5 Seleção e Implementação do Algoritmo 11

3.6 Treinamento do Modelo 11

3.7 Avaliação do Desempenho 11

3.8 Otimização e Ajustes 12

3.9 Implantação e Monitoramento 13

4 REFERÊNCIAS 14

1 INTRODUÇÃO

Este projeto propõe o desenvolvimento de um sistema de recomendação de cursos educacionais utilizando como base de treinamento avaliações de usuários da plataforma Coursera. A partir de técnicas de filtragem colaborativa e análise de padrões de consumo de conteúdo, busca-se recomendar cursos relevantes de forma personalizada, contribuindo para democratizar o acesso ao conhecimento.

1.1 Contexto do Trabalho

O crescimento das plataformas de ensino online transformou a forma como pessoas aprendem e desenvolvem habilidades. Plataformas como Coursera, edX e Udemy oferecem catálogos com milhares de cursos em áreas diversas e dependem de sistemas de recomendação para conectar aprendizes ao conteúdo mais adequado ao seu perfil e objetivos. Esses sistemas operam analisando o histórico de interações, avaliações e preferências dos usuários, produzindo sugestões personalizadas que aumentam o engajamento e a taxa de conclusão dos cursos.

A expansão dos MOOCs (Massive Open Online Courses) trouxe um desafio novo: a sobrecarga de informação. Com tantas opções disponíveis, o estudante frequentemente não consegue identificar qual curso atende melhor às suas necessidades e nível de conhecimento. Essa dificuldade é crítica para pessoas em situação de vulnerabilidade socioeconômica, que buscam na educação digital uma forma de requalificação e inserção no mercado de trabalho. Nesse contexto, sistemas de recomendação eficazes tornam-se ferramentas essenciais de inclusão educacional.

1.2 Motivação

A motivação central deste projeto é compreender, de forma prática, como sistemas de recomendação são construídos e aplicados em um contexto com impacto social direto. A área de educação digital despertou o interesse do grupo pela combinação entre a riqueza dos dados disponíveis e a diversidade de perfis de aprendizes que ela concentra — do estudante universitário ao profissional em busca de requalificação.

Além disso, sistemas de recomendação são uma das aplicações mais disseminadas de aprendizado de máquina na indústria. Estudar sua construção no domínio educacional permite ao grupo consolidar conhecimentos sobre pré-processamento de dados, modelagem e avaliação de desempenho, conectando teoria e prática.

1.3 Justificativa

A relevância deste projeto se sustenta em dois eixos. O primeiro é acadêmico: a construção de um sistema de recomendação envolve um pipeline completo de ciência de dados, desde a coleta e limpeza dos dados até o treinamento, a avaliação e a interpretação dos resultados. O segundo eixo é social: plataformas de educação online dependem da qualidade dessas recomendações para engajar estudantes, reduzir a evasão e ampliar o alcance do conhecimento para populações que historicamente têm menos acesso à educação formal.

O mercado de educação online no Brasil e no mundo cresce de forma acelerada, impulsionado pela democratização do acesso à internet e pela crescente demanda por requalificação profissional. Sistemas de recomendação eficazes nesse segmento

podem ajudar mais pessoas a encontrar cursos adequados ao seu perfil, nível de conhecimento e objetivos de carreira, reduzindo a barreira de entrada no aprendizado contínuo.

Este projeto se alinha a dois Objetivos de Desenvolvimento Sustentável (ODS) da ONU. O primeiro é a **ODS 4 – Educação de Qualidade**: ao recomendar cursos educacionais adequados ao perfil e aos objetivos de cada aprendiz, o sistema contribui para democratizar o acesso ao conhecimento, ampliar oportunidades de aprendizado e reduzir desigualdades educacionais. O segundo é a **ODS 8 – Trabalho Decente e Crescimento Econômico**: ao orientar estudantes para cursos alinhados às demandas do mercado de trabalho, o sistema contribui para a qualificação profissional e a empregabilidade, especialmente de pessoas em busca de recolocação ou primeiro emprego.

1.4 Objetivos

Objetivo Geral:

Desenvolver um sistema de recomendação de cursos educacionais baseado em avaliações explícitas de usuários da plataforma Coursera, combinando filtragem colaborativa como abordagem principal e filtragem baseada em conteúdo como abordagem complementar, formando uma solução híbrida capaz de sugerir cursos personalizados com base no histórico de interações dos aprendizes e nas características dos cursos.

Objetivos Específicos:

- Coletar e preparar a base de dados Course Reviews on Coursera (1,45 milhão de avaliações, disponível no Kaggle), realizando limpeza e transformações necessárias para o treinamento do modelo.
- Realizar análise exploratória dos dados, identificando padrões de avaliação, distribuição de notas e comportamento dos aprendizes.
- Implementar filtragem colaborativa (SVD e/ou KNN) como técnica principal, explorando padrões de avaliação entre usuários e cursos, e filtragem baseada em conteúdo (TF-IDF) como abordagem complementar para tratamento de novos usuários sem histórico (problema de cold start).
- Avaliar o desempenho do modelo utilizando métricas adequadas a sistemas de recomendação, como RMSE, MAE e Precisão@K.
- Documentar e apresentar os resultados obtidos, discutindo pontos fortes, limitações e possíveis extensões do sistema para outros contextos educacionais.

2 REFERENCIAL TEÓRICO

A fundamentação deste projeto se apoia em três estudos: Jena et al. (2023) e Suryani, Pangestu e Pradana (2024), que trabalham com filtragem colaborativa aplicada a cursos online, e Butmeh e Abu-Issa (2024), que investigam a abordagem híbrida em cenários de cold start em e-learning.

Um sistema de recomendação é uma ferramenta que filtra um grande volume de opções e sugere ao usuário aquelas que têm maior probabilidade de ser relevantes para ele. O princípio é simples: o sistema reduz a sobrecarga de escolha apresentando um subconjunto personalizado. Essa funcionalidade é central em plataformas de e-commerce, streaming de mídia e, cada vez mais, em plataformas de educação online.

No contexto educacional, o problema de recomendação ganha uma dimensão particular. Plataformas como o Coursera oferecem catálogos extensos de cursos em áreas diversas, e o aprendiz frequentemente não dispõe de critérios claros para escolher entre opções aparentemente similares. Um sistema de recomendação eficaz nesse cenário pode conectar o estudante ao curso mais adequado ao seu nível de conhecimento, área de interesse e objetivos profissionais, contribuindo para reduzir a evasão e aumentar o engajamento.

Existem três grandes famílias de abordagens para construir um sistema de recomendação. A filtragem baseada em conteúdo analisa os atributos dos itens (título, descrição, área temática) e recomenda itens semelhantes aos que o usuário já consumiu. A filtragem colaborativa não depende dos atributos dos itens: ela identifica padrões nas avaliações de múltiplos usuários para inferir preferências. A abordagem híbrida combina as duas anteriores, buscando compensar as limitações de cada uma — por exemplo, usando filtragem colaborativa para usuários com histórico e filtragem por conteúdo para novos usuários sem avaliações prévias.

A filtragem colaborativa parte de uma premissa intuitiva: se dois usuários avaliaram os mesmos cursos de forma semelhante no passado, é provável que continuem concordando em cursos futuros. Essa ideia pode ser explorada de duas formas. Nos métodos baseados em memória, o sistema compara diretamente os vetores de avaliações — seja entre usuários (user-based) ou entre itens (item-based) — utilizando métricas de similaridade como o cosseno do ângulo entre os vetores. O resultado é uma lista de vizinhos mais próximos cujas avaliações são usadas para estimar a nota que o usuário daria a um item ainda não avaliado.

Nos métodos baseados em modelo, a abordagem é diferente: em vez de comparar vetores completos, a matriz de avaliações (usuário × item) é decomposta em fatores latentes de menor dimensão. A técnica mais conhecida é a SVD (Singular Value Decomposition), que representa cada usuário e cada item como um vetor em um espaço latente, onde a proximidade entre os vetores indica afinidade. Outra vertente utiliza redes neurais para capturar interações não lineares entre usuários e itens, como no caso do NCF (Neural Collaborative Filtering).

Um ponto relevante para este projeto é a escolha da métrica de similaridade na abordagem item-based. A similaridade por cosseno padrão calcula o ângulo entre dois vetores de avaliações, mas ignora o fato de que usuários diferentes têm escalas de

avaliação diferentes — alguns tendem a dar notas altas para tudo, outros são mais rigorosos. A similaridade por cosseno ajustada (adjusted cosine similarity) corrige esse viés subtraindo a média de cada usuário antes do cálculo, produzindo uma medida mais fiel da concordância real entre os itens. Resultados na literatura indicam que essa correção melhora a estabilidade das predições, especialmente em ratings extremos (Suryani, Pangestu e Pradana, 2024).

Para a predição do rating de um item não avaliado, duas fórmulas são comuns. A weighted sum pondera as avaliações dos K vizinhos mais próximos pela sua similaridade com o item alvo. A adjusted weighted sum acrescenta a média do item à predição, o que compensa diferenças de popularidade entre cursos. Experimentos com o dataset Coursera mostram que a combinação adjusted weighted sum com adjusted cosine similarity e K entre 120 e 160 vizinhos oferece os menores erros de predição (Suryani, Pangestu e Pradana, 2024). Do lado dos métodos baseados em modelo, comparações entre KNN, SVD e NCF em cenários de recomendação de cursos indicam que o KNN, apesar de ser o método mais simples, pode oferecer desempenho competitivo frente a abordagens mais sofisticadas (Jena et al., 2023).

A filtragem colaborativa descrita na seção anterior depende de um histórico de avaliações para funcionar. Quando um usuário ou item é novo no sistema e não possui avaliações registradas, o algoritmo não consegue calcular similaridades e, portanto, não gera recomendações. Essa situação é conhecida como cold start (partida a frio) e representa a principal limitação prática da filtragem colaborativa pura, especialmente em contextos educacionais onde a rotatividade de alunos é alta.

A resposta mais comum ao cold start é a adoção de uma abordagem híbrida, que combina dois caminhos complementares: filtragem colaborativa para usuários que já possuem histórico e filtragem baseada em conteúdo para os demais. Na filtragem baseada em conteúdo, as recomendações são geradas a partir dos atributos dos próprios cursos — como título, área temática, nível de dificuldade e instituição — sem depender de avaliações prévias. Butmeh e Abu-Issa (2024) demonstram que essa combinação é particularmente eficaz em plataformas de e-learning, onde o cenário de cold start é frequente.

Existem diferentes estratégias para implementar a hibridização: switching alterna entre os dois métodos conforme a disponibilidade de dados; weighting atribui pesos a cada componente; cascading usa um método para filtrar candidatos e outro para ordenar. Para este projeto, a estratégia de switching é a mais adequada, pois o piloto prevê usuários sem qualquer histórico no Coursera, configurando um cenário de cold start total onde o componente de conteúdo precisa operar de forma autônoma.

Bases de avaliações de cursos online compartilham três características que exigem tratamento cuidadoso antes da modelagem: esparsidade, ruído e viés de avaliação. A esparsidade é a mais impactante: em uma plataforma com centenas de cursos e centenas de milhares de usuários, a grande maioria das células da matriz usuário × curso fica vazia, pois cada pessoa avalia apenas uma fração mínima do catálogo. A análise exploratória deste projeto, apresentada na Etapa 1, confirmou uma densidade de apenas 0,84% na matriz de interações do dataset Coursera — ou seja, mais de 99% dos pares possíveis não possuem avaliação registrada.

O pipeline típico de pré-processamento para filtragem colaborativa segue uma sequência lógica. Primeiro, os datasets de avaliações e de metadados dos cursos são integrados por meio de uma chave comum (course_id). Em seguida, valores ausentes e registros duplicados são removidos ou tratados. A etapa seguinte é a construção da matriz pivô, onde cada linha representa um usuário, cada coluna um curso, e cada célula contém a avaliação correspondente — ou zero quando não há interação. Dependendo do algoritmo, essa matriz pode ser convertida para formato esparso (como CSR — Compressed Sparse Row) para otimizar o uso de memória, ou normalizada para compatibilidade com o modelo.

Uma decisão de projeto importante é a filtragem de esparsidade: definir limiares mínimos de atividade para manter um usuário ou curso na base. A literatura utiliza indicadores como o User Specific Sparsity (USS) e o Item Specific Sparsity (ISS), que medem a proporção de células vazias por linha e por coluna, respectivamente. Ao definir um limiar máximo de esparsidade (por exemplo, 0,96), descartam-se usuários com poucas avaliações e cursos com pouca visibilidade, concentrando a modelagem nos pares com informação suficiente para produzir recomendações confiáveis. Essa estratégia pode reduzir drasticamente o tamanho da base — no caso do dataset Coursera, de 623 cursos para 233 e de 1,45 milhão de registros para cerca de 39 mil (Suryani, Pangestu e Pradana, 2024) — mas aumenta a qualidade do sinal disponível para o modelo.

O viés de avaliação também precisa ser considerado. Conforme identificado na análise exploratória deste projeto, 95,2% dos usuários do Coursera atribuem nota média igual ou superior a 4,0. Essa concentração no topo da escala dificulta a diferenciação entre cursos e entre preferências de usuários. A normalização dos ratings — subtraindo a média de cada usuário — é uma técnica simples que atenua esse efeito e permite que o modelo capture diferenças reais de preferência em vez de apenas reproduzir a tendência geral de avaliações positivas.

A avaliação de um sistema de recomendação requer métricas que capturem dois aspectos distintos: a precisão das predições de rating e a qualidade do ranking das recomendações. Para o primeiro aspecto, as métricas mais utilizadas são o MAE (Mean Absolute Error) e o RMSE (Root Mean Square Error). O MAE calcula a média dos erros absolutos entre os ratings preditos e os reais, oferecendo uma medida direta e interpretável do erro típico do modelo. O RMSE segue a mesma lógica, mas eleva os erros ao quadrado antes de calcular a média, o que penaliza com mais intensidade predições muito distantes do valor real. Essa propriedade torna o RMSE mais sensível a erros grandes, sendo particularmente útil em bases com ratings extremos.

Para avaliar a qualidade do ranking — isto é, se os cursos mais relevantes aparecem nas primeiras posições da lista de recomendações — utilizam-se métricas como Hit Rate (proporção de usuários para os quais pelo menos um item relevante aparece no top-K) e Precisão@K (proporção de itens relevantes entre os K recomendados). A Precisão@K é especialmente útil porque reflete a experiência real do usuário: na prática, o aprendiz visualiza apenas as primeiras sugestões, e a qualidade dessas posições iniciais define a utilidade percebida do sistema.

Para este projeto, as métricas escolhidas são RMSE, MAE e Precisão@K. Essa combinação permite avaliar tanto a acurácia das predições quanto a utilidade prática

das recomendações. Os valores de referência disponíveis na literatura para o mesmo dataset Coursera — MAE de aproximadamente 0,48 e RMSE de aproximadamente 0,76 para filtragem colaborativa item-based (Suryani, Pangestu e Pradana, 2024) — servem como baseline para comparação direta com os resultados do sistema proposto.

Os conceitos e técnicas descritos nas seções anteriores fornecem a base para as decisões de projeto. A escolha de SVD e KNN como algoritmos principais de filtragem colaborativa é sustentada por evidências de que esses métodos oferecem desempenho competitivo em cenários de recomendação de cursos, inclusive frente a abordagens mais complexas como redes neurais (Jena et al., 2023). O dataset Coursera/Kaggle adotado pelo grupo é o mesmo utilizado por Suryani, Pangestu e Pradana (2024), o que permite comparação direta dos resultados com os baselines reportados na literatura (MAE ≈ 0,48 e RMSE ≈ 0,76 para filtragem colaborativa item-based).

A principal diferença entre este projeto e os estudos de referência está na adoção de uma abordagem híbrida. Enquanto Jena et al. (2023) trabalham exclusivamente com filtragem colaborativa e Suryani, Pangestu e Pradana (2024) focam na otimização de uma única técnica item-based, este projeto combina filtragem colaborativa como componente principal com filtragem baseada em conteúdo (TF-IDF sobre metadados textuais dos cursos) como componente complementar. Essa estratégia é respaldada por Butmeh e Abu-Issa (2024), que demonstram a eficácia de sistemas híbridos com switching em plataformas de e-learning, especialmente em cenários de cold start. A decisão não é arbitrária: ela decorre diretamente das condições previstas para a validação do sistema.

O plano de projeto inclui um piloto de pequena escala com usuários reais, que provavelmente não possuem histórico de avaliações na plataforma Coursera. Nesse cenário, a filtragem colaborativa não dispõe de dados de interação para gerar recomendações — é o problema de cold start em sua forma mais severa, afetando potencialmente 100% dos participantes do teste. A filtragem baseada em conteúdo se torna, portanto, não apenas um complemento teórico, mas a via principal de recomendação durante o piloto. O sistema precisará recomendar cursos com base exclusivamente nos metadados disponíveis (título, instituição, área temática) e em eventuais preferências declaradas pelo usuário, sem poder recorrer a padrões de avaliação colaborativos.

Essa condição impõe requisitos concretos ao pipeline: o componente de TF-IDF precisa funcionar de forma autônoma, produzindo recomendações úteis mesmo na ausência total de ratings. A avaliação do piloto deverá priorizar métricas de ranking como Precisão@K, já que não haverá ratings reais para comparar com predições. Os resultados desse teste fornecerão os primeiros dados de interação que permitirão ativar o componente colaborativo em iterações futuras.

3 METODOLOGIA

Esta seção descreve os procedimentos adotados em cada etapa do projeto, desde a coleta dos dados até a avaliação dos modelos. A Figura 1 apresenta o esquema geral da metodologia.

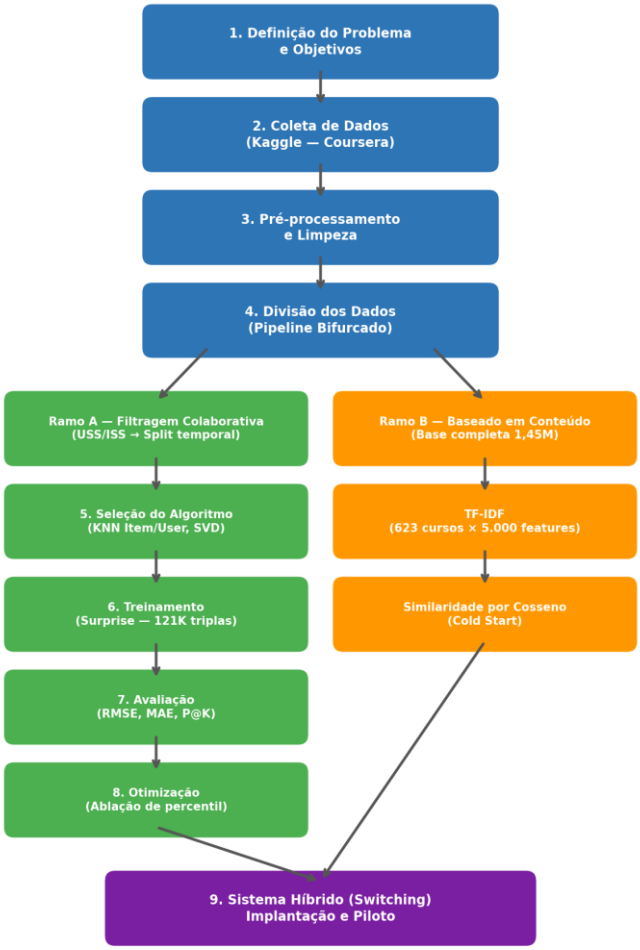

Figura 1: Metodologia utilizada no projeto

3.1 Definição do Problema e Objetivos

O problema central deste projeto é a recomendação personalizada de cursos em plataformas de educação online. Dado um usuário com histórico de avaliações, o sistema deve predizer quais cursos ainda não avaliados teriam maior nota e apresentá-los como recomendações. Para usuários sem histórico (cold start), o sistema deve recorrer às características textuais dos cursos para gerar sugestões. Os objetivos gerais e específicos estão detalhados na Seção 1.4.

3.2 Coleta de Dados

A base de dados utilizada é a Course Reviews on Coursera, disponível publicamente no Kaggle (Muhammad, 2020). Ela contém dois arquivos: um catálogo de 623 cursos

com nome, instituição e URL, e um arquivo com 1.454.711 avaliações contendo texto da review, nome do avaliador, data e nota de 1 a 5 estrelas. As avaliações cobrem o período de agosto de 2015 a outubro de 2020. A base foi escolhida por ser a mesma utilizada por Suryani, Pangestu e Pradana (2024), o que permite comparação direta de resultados.

3.3 Pré-processamento e Limpeza dos Dados

O pré-processamento seguiu três etapas sequenciais. A primeira foi a sanitização: conversão das datas para formato padronizado, remoção do prefixo “By” dos nomes de avaliadores e tratamento de caracteres especiais (espaços não-quebráveis). A segunda etapa foi a deduplicação: remoção de todas as avaliações vinculadas ao perfil genérico “Deleted A”, que agrega contas apagadas da plataforma e distorce o perfil de atividade, seguida da eliminação de pares duplicados (avaliador, curso), mantendo apenas a avaliação mais recente de cada par. Essa etapa reduziu a base de 1,45 milhão para 505.733 registros.

A terceira etapa foi o corte por percentil: remoção de usuários acima do percentil 99,9 de atividade (mais de 33 avaliações). Nomes de avaliadores na base do Coursera são abreviados e não verificados, o que faz com que perfis com alta contagem de reviews provavelmente agreguem múltiplas pessoas sob o mesmo rótulo. A análise exploratória (Etapa 1) confirmou que 99% dos usuários possuem até 36 avaliações. A base resultante contém 493.011 registros.

3.4 Divisão dos Dados

O pipeline de dados foi dividido em dois ramos para alimentar os componentes do sistema híbrido.

O Ramo A (filtragem colaborativa) partiu da base deduplicada e filtrada por percentil (493 mil registros). Sobre ela foram aplicados filtros de esparsidade baseados nos indicadores USS (User Specific Sparsity) e ISS (Item Specific Sparsity), com limiar de 0,96, conforme a abordagem de Suryani, Pangestu e Pradana (2024). Usuários com esparsidade acima do limiar (poucas avaliações em relação ao máximo observado) e cursos com pouca visibilidade foram descartados. O filtro reteve 75.222 usuários e 228 cursos, totalizando 236.451 avaliações. A matriz pivô resultante (usuário × curso) possui densidade de 1,38%.

A divisão treino/teste foi temporal: avaliações anteriores a janeiro de 2020 compõem o conjunto de treino (121.009 registros, 49.066 usuários, 223 cursos) e avaliações de 2020 em diante compõem o teste (115.442 registros, 50.552 usuários, 228 cursos). Essa divisão simula um cenário real onde o sistema é treinado com dados passados e avaliado com dados futuros. O pico de avaliações em 2020, provocado pela pandemia, funciona como teste de estresse natural para o modelo.

O Ramo B (filtragem baseada em conteúdo) partiu da base sanitizada completa (1,45 milhão de registros) para maximizar o volume textual disponível. Avaliações com menos de 5 palavras foram descartadas por não conterem informação útil para representação textual, resultando em 1.164.414 registros. Para cada curso, foi construído um documento textual concatenando nome do curso, instituição e texto agregado das avaliações. Sobre esse corpus, foi aplicada a técnica TF-IDF (Term

Frequency–Inverse Document Frequency) com limite de 5.000 features e bigramas (ngram 1-2), gerando uma matriz esparsa de 623 cursos × 5.000 dimensões.

3.5 Seleção e Implementação do Algoritmo

Foram implementados três algoritmos de filtragem colaborativa utilizando a biblioteca Surprise (Python):

KNN Item-Based (KNNWithMeans): calcula a similaridade por cosseno entre pares de cursos e prediz ratings com base nos K=40 vizinhos mais próximos. O algoritmo aplica mean-centering automaticamente, subtraindo a média de cada item antes do cálculo de similaridade.

KNN User-Based (KNNWithMeans): calcula a similaridade por cosseno entre pares de usuários, com K=40 e suporte mínimo de 5 itens em comum para o cálculo de similaridade. A restrição de suporte mínimo é necessária para viabilizar a matriz de similaridade entre 49.066 usuários.

SVD (Singular Value Decomposition): decompõe a matriz de avaliações em 50 fatores latentes, treinado por 20 épocas com os parâmetros padrão da biblioteca Surprise.

Para o componente content-based (Ramo B), a similaridade entre cursos é calculada pelo cosseno entre os vetores TF-IDF correspondentes. Quando um usuário sem histórico informa preferências ou palavras-chave, o sistema converte essa entrada em um vetor TF-IDF e retorna os cursos mais similares.

3.6 Treinamento do Modelo

O treinamento dos modelos de filtragem colaborativa utilizou o conjunto de treino do Ramo A: 121.009 triplas no formato (usuário, curso, nota). O KNN Item-Based treinou em menos de 1 segundo, correspondendo ao cálculo da matriz de similaridade entre 223 cursos. O KNN User-Based levou 55 segundos, refletindo o custo computacional de calcular similaridades entre 49.066 usuários. O SVD treinou em 0,2 segundos.

A avaliação foi conduzida sobre o subconjunto do teste contendo apenas usuários e cursos presentes no treino (55.472 triplas), isolando o desempenho puro da filtragem colaborativa. As 59.970 triplas restantes do teste envolvem usuários ou cursos ausentes do treino (cenários de cold start) e serão tratadas pelo componente content-based na Etapa 4.

3.7 Avaliação do Desempenho

Os modelos foram avaliados por três métricas: RMSE (Root Mean Square Error), MAE (Mean Absolute Error) e Precisão@K, com limiar de relevância fixado em 4 estrelas. A Tabela 1 apresenta os resultados comparativos, incluindo o baseline de referência da literatura.

Modelo	RMSE	MAE	P@5	P@10
KNN Item-Based (K=40)	0,8369	0,5058	0,3857	0,2129
KNN User-Based (K=40)	0,8907	0,5199	0,3840	0,2127

Modelo	RMSE	MAE	P@5	P@10
SVD (50 fatores)	**0,7158**	**0,4596**	0,3856	0,2129
Ref. Suryani (K=150)	*0,7882*	*0,4791*	—	—

Tabela 1: Resultados comparativos dos modelos de filtragem colaborativa

O SVD obteve o menor erro de predição, superando o baseline reportado por Suryani, Pangestu e Pradana (2024) para KNN item-based com K=150 vizinhos. O KNN Item-Based e o KNN User-Based ficaram acima do baseline em RMSE e MAE, o que pode ser atribuído ao valor de K=40 utilizado (menor que o ótimo de 120-160 reportado na referência). A Precisão@5 foi equivalente entre os três modelos (~0,386), indicando que a qualidade do ranking dos cursos recomendados não se diferencia de forma significativa entre os algoritmos testados.

A análise de erros do KNN Item-Based revelou viés sistemático: o modelo superestima notas baixas (viés positivo para ratings 1 e 2) e subestima notas altas (viés negativo para rating 5). Esse padrão reflete a concentração de 79,5% das notas do teste em 5 estrelas, que empurra as predições em direção à moda da distribuição e dificulta a captura de avaliações fora do padrão.

3.8 Otimização e Ajustes

Para avaliar o impacto do corte de percentil no pipeline, foi conduzido um teste comparativo. O SVD foi treinado com os mesmos hiperparâmetros sobre uma base alternativa, construída sem o corte de percentil (apenas deduplicação seguida dos filtros USS/ISS). Essa base alternativa resultou em 62.781 triplas de treino — quase metade do volume obtido com corte (121.009). A redução ocorre porque, sem o corte prévio, o filtro USS/ISS opera sobre uma distribuição diferente de atividade por usuário e descarta mais registros.

O RMSE sem corte de percentil foi 0,7384, contra 0,7158 com corte — uma diferença de 0,023 pontos. O MAE seguiu a mesma direção: 0,4861 sem corte versus 0,4596 com corte. O resultado confirma que a remoção de perfis ruidosos antes da filtragem de esparsidade melhora a qualidade das predições, embora o efeito seja modesto. A maior parte do ganho do SVD sobre os baselines da literatura vem da diferença entre algoritmos (SVD versus KNN), não do pré-processamento.

Além do corte de percentil, foi realizada a otimização do parâmetro K (número de vizinhos) para o modelo KNNWithMeans, tanto na variante item-based quanto na user-based. A faixa testada incluiu dez valores: 10, 20, 40, 60, 80, 100, 120, 150, 180 e 220. A escolha dessa faixa cobre o valor padrão usado na etapa anterior (K = 40) e o valor sugerido por Suryani, Pangestu e Pradana (2024), que indicam K ótimo entre 120 e 160.

O procedimento aproveitou uma propriedade do KNNWithMeans na biblioteca Surprise: a matriz de similaridade é calculada uma única vez durante o treinamento, e o parâmetro K é aplicado apenas na etapa de predição, quando se seleciona quantos vizinhos contribuem para a estimativa. Isso permitiu computar a similaridade uma vez por modo (item e user) e repetir a avaliação para cada valor de K sem retreinar o modelo.

Na variante item-based, as métricas se mostraram praticamente insensíveis ao valor de K. Com K = 10, o RMSE foi 0,8370; a partir de K = 20, estabilizou em 0,8369 e permaneceu nesse patamar até K = 220. MAE e Precision@10 seguiram o mesmo padrão: 0,5058 e 0,2129, respectivamente, sem variação perceptível. Esse comportamento se explica pelo catálogo reduzido (223 cursos): o número efetivo de vizinhos com similaridade não nula satura rapidamente, e vizinhos adicionais não alteram a predição.

Na variante user-based, a sensibilidade foi igualmente baixa, porém por razão distinta. A matriz user–user envolve 49.066 usuários, mas a esparsidade extrema (cada usuário avaliou poucos cursos) faz com que a maioria dos pares não atinja o min_support = 5 exigido. O melhor RMSE (0,8907) foi obtido com K = 150, contra 0,8908 com K = 10 — uma diferença de 0,0001. O MAE variou entre 0,5201 (K = 10) e 0,5199 (K ≥ 150).

Com base nesses resultados, os valores ótimos selecionados foram K = 40 para item-based e K = 150 para user-based, ambos por critério de menor RMSE. Esses parâmetros serão usados na comparação final entre modelos, substituindo o K = 40 usado por padrão na etapa anterior.

3.9 Implantação e Monitoramento

A implantação do sistema está prevista para a Etapa 4 do projeto. O plano inclui três frentes: construção de uma interface para coleta de preferências do usuário, integração dos componentes colaborativo (SVD) e content-based (TF-IDF) em uma arquitetura de switching, e condução de um piloto com usuários reais para avaliação qualitativa das recomendações. O componente content-based será ativado automaticamente para usuários sem histórico de avaliações, enquanto o SVD operará para aqueles com dados suficientes no sistema.

4 REFERÊNCIAS

BUTMEH, H.; ABU-ISSA, A. Hybrid attribute-based recommender system for personalized e-learning with emphasis on cold start problem. Frontiers in Computer Science, v. 6, art. 1404391, 2024. DOI: https://doi.org/10.3389/fcomp.2024.1404391. Acesso em: mar. 2026.

MUHAMMAD, Iqbal. Course Reviews on Coursera. Kaggle, 2020. Disponível em: https://www.kaggle.com/datasets/imuhammad/course-reviews-on-coursera. Acesso em: fev. 2026.

HAFSA, Mounir et al. E-learning recommender system dataset. Data in Brief, v. 47, 2023. Disponível em: https://doi.org/10.1016/j.dib.2023.108942. Acesso em: fev. 2026.

ONU BRASIL. Objetivos de Desenvolvimento Sustentável. Disponível em: https://brasil.un.org/pt-br/sdgs. Acesso em: fev. 2026.

JENA, K. K.; BHOI, S. K.; MALIK, T. K.; SAHOO, K. S.; JHANJHI, N. Z.; BHATIA, S.; AMSAAD, F. E-Learning Course Recommender System Using Collaborative Filtering Models. Electronics, Basel, v. 12, n. 1, art. 157, 2023. Disponível em: https://doi.org/10.3390/electronics12010157. Acesso em: mar. 2026.

SURYANI, M.; PANGESTU, R.; PRADANA, A. Optimizing Item-based Collaborative Filtering for Course Recommendation: a Case Study with Coursera Data. In: 2024 INTERNATIONAL CONFERENCE ON INFORMATION TECHNOLOGY SYSTEMS AND INNOVATION (ICITSI), Bandung, 2024. p. 570–575. DOI: 10.1109/ICITSI65184.2024.10929184. Acesso em: mar. 2026.